

PR_06.2 Dani Gayol Rodríguez

PR_06.2 Dani Gayol Rodríguez.....	1
Gestion de tablas y formatos.....	1
1. Carga de Datos Delimitados (Básico):	2
2. Definición de Esquema y Comentarios:.....	2
3. Simulación de Pérdida de Datos (DROP TABLE):	3
Tipos de Datos Complejos	4
1. Uso de STRUCT (Información Personal):.....	5
2. Uso de ARRAY (Géneros de Película):.....	5
3. Uso de MAP (Puntuación de Usuarios por Ocupación):.....	5
Consultas Básicas y JOINS.....	6
1. Agregación Básica:	7
2. Filtrado y Agrupación:	7
3. INNER JOIN:	8
4. LEFT OUTER JOIN:	9
5. LEFT SEMI JOIN (Simulación de IN/EXISTS):	9

Gestion de tablas y formatos

1. Carga de Datos Delimitados (Básico):

```
1 CREATE EXTERNAL TABLE ml_ratings_ext (
2     user_id INT,
3     movie_id INT,
4     rating INT,
5     time_stamp BIGINT
6 )
7 ROW FORMAT DELIMITED
8 FIELDS TERMINATED BY '\t'
9 LINES TERMINATED BY '\n'
10 LOCATION '/user/hive/movielens/u.data';
```

```
1 LOAD DATA INPATH '/user/maria_dev/movielens/u.data' INTO TABLE ml_ratings_ext;
```

	ml_ratings_ext.user_id	ml_ratings_ext.movie_id	ml_ratings_ext.rating	ml_ratings_ext.time_stamp
196	242	3	881250949	
186	302	3	891717742	
22	377	1	878887116	
244	51	2	880606923	
166	346	1	886397596	
298	474	4	884182806	

2. Definición de Esquema y Comentarios:

```

1 CREATE TABLE ml_users_managed (
2     user_id INT,
3     age INT,
4     gender STRING,
5     occupation STRING COMMENT 'Tipo de ocupación puesta por el usuario',
6     zipcode STRING
7 )
8 COMMENT 'Tabla gestionada con información de usuarios'
9 ROW FORMAT DELIMITED
10 FIELDS TERMINATED BY '|'
11 STORED AS TEXTFILE;

```

```

1 LOAD DATA INPATH '/user/maria_dev/movielens/u.user' INTO TABLE ml_users_managed;

```

	ml_users_managed.user_id	ml_users_managed.age	ml_users_managed.gender	ml_users_managed.occupation	ml_users_managed.zipcode
1	24	M	technician	85711	
2	53	F	other	94043	
3	23	M	writer	32067	
4	24	M	technician	43537	
5	33	F	other	15213	

3. Simulación de Pérdida de Datos (DROP TABLE):

Para la tabla “ml_ratings_ext”, al ser “external”, Hive borra el metadata pero no elimina los archivos del directorio asociado

```

1 DROP TABLE ml_ratings_ext;

```

The screenshot shows the Apache Hive Metastore UI interface. At the top, there's a header with 'TABLES | 4'. Below it is a search bar with a magnifying glass icon. The main area lists four tables: 'ml_users_managed' (highlighted with a yellow background), 'peliculas', 'usuarios', and 'votos'. Each table entry includes a small icon and its name.

TABLES 4
ml_users_managed
peliculas
usuarios
votos

Name >

- ↳ hive
- ↳ user
- ↳ /

←

□ u.data

Para la tabla “ml_users_managed”, al ser “managed“, Hive controla el directorio y borra la carpeta y su contenido

TABLES | 3

Search

- grid peliculas
- grid usuarios
- grid votos

Tipos de Datos Complejos

1. Uso de STRUCT (Información Personal):

```
1 CREATE TABLE ml_user_info (
2     user_id INT,
3     personal_data STRUCT<
4         age: INT,
5         gender: STRING
6     >,
7     occupation STRING,
8     zipcode STRING
9 )
10 ROW FORMAT DELIMITED
11 FIELDS TERMINATED BY '|';
```

```
1 SELECT user_id, personal_data.gender
2 FROM ml_user_info
3 WHERE personal_data.gender = 'F';
```

2. Uso de ARRAY (Géneros de Película):

Primera consulta

```
1 SELECT movie_id, size(genres_list) AS num_genres
2 FROM ml_movies_array;
```

Segunda consulta

```
1 SELECT genres_list[1]
2 FROM ml_movies_array
3 WHERE movie_id = 50;
```

3. Uso de MAP (Puntuación de Usuarios por Ocupación):

```
1 SELECT map_keys(avg_rating_by_occupation)
2 FROM ml_occupation_ratings;
```


Consultas Básicas y JOINS

1. Agregación Básica:

Como eliminamos esta tabla anteriormente, solo basta con crearla otra vez ya que los datos siguen guardados

```
1 CREATE EXTERNAL TABLE ml_ratings_ext (
2     user_id INT,
3     movie_id INT,
4     rating INT,
5     time_stamp BIGINT
6 )
7 ROW FORMAT DELIMITED
8 FIELDS TERMINATED BY '\t'
9 LINES TERMINATED BY '\n'
10 LOCATION '/user/hive/movielens/u.data';
```

Ahora hacemos la consulta

```
1 SELECT AVG(rating) AS avg_rating
2 FROM ml_ratings_ext;
```

avg_rating

3.52986

2. Filtrado y Agrupación:

Como eliminamos esta tabla anteriormente, aquí si hay que crear la tabla y insertarle los datos otra vez

```
1 CREATE TABLE ml_users_managed (
2     user_id INT,
3     age INT,
4     gender STRING,
5     occupation STRING COMMENT 'Tipo de ocupación declarada por el usuario',
6     zipcode STRING
7 )
8 COMMENT 'Tabla gestionada con información de usuarios MovieLens'
9 ROW FORMAT DELIMITED
10 FIELDS TERMINATED BY '|'
11 STORED AS TEXTFILE;
```

```
1 LOAD DATA INPATH '/user/maria_dev/movielens/u.user' INTO TABLE ml_users_managed;
```

Ahora ya podemos hacer la consulta

```
1 SELECT gender, occupation, COUNT(*) AS total_users
2 FROM ml_users_managed
3 GROUP BY gender, occupation
4 ORDER BY total_users DESC;
```

gender	occupation	total_users
M	student	136
M	other	69
M	educator	69
M	engineer	65
F	student	60

3. INNER JOIN:

Si quieres que la media no salga con muchas decimales puedes usar “ROUND” para redondear al número de decimales que quieras

```
1 SELECT u.occupation, AVG(r.rating) AS avg_rating
2 FROM ml_ratings_ext r
3 INNER JOIN ml_users_managed u
4     ON r.user_id = u.user_id
5 GROUP BY u.occupation
6 ORDER BY avg_rating DESC;
```

u.occupation	avg_rating
none	3.779134295227525
lawyer	3.7353159851301116
doctor	3.688888888888889
educator	3.6706206312221985
artist	3.653379549393414

4. LEFT OUTER JOIN:

```
1 CREATE TABLE unrated_users (user_id INT);
2
3 INSERT INTO unrated_users VALUES (1), (2), (3), (4), (5);

1 SELECT u.user_id, r.rating
2 FROM ml_users_managed u
3 LEFT OUTER JOIN ml_ratings_ext r
4     ON u.user_id = r.user_id
5 WHERE r.rating IS NULL;
```

5. LEFT SEMI JOIN (Simulación de IN/EXISTS):

```
1 SELECT u.user_id
2 FROM ml_users_managed u
3 LEFT SEMI JOIN ml_ratings_ext r
4     ON u.user_id = r.user_id
5 WHERE u.occupation = 'programmer';
```

u.user_id

17

29

45

53

55

58

82