



Big Data

Enviar tareas como Pasos (Steps) a clústeres EMR.

CONTENIDO

APARTADO A

1.- Siguiendo los pasos que se explican en el tema, crea un clúster Hadoop EMR con 1 *master* y dos nodos. Selecciona la opción *Core Hadoop (versión 7.0.0)*. No te olvides de seleccionar Sqoop, ya que lo utilizaremos en las prácticas siguientes.

emr-7.0.0 ▼

Paquete de aplicaciones

Spark Interactive	Core Hadoop	Flink	HBase	Presto	Trino
<input type="checkbox"/> AmazonCloudWatchAgent 1.300031.1	<input type="checkbox"/> Flink 1.18.0	<input type="checkbox"/> HBase 2.4.17			
<input type="checkbox"/> HCatalog 3.1.3	<input checked="" type="checkbox"/> Hadoop 3.3.6	<input checked="" type="checkbox"/> Hive 3.1.3			
<input checked="" type="checkbox"/> Hue 4.11.0	<input type="checkbox"/> JupyterEnterpriseGateway 2.6.0	<input type="checkbox"/> JupyterHub 1.5.0			
<input type="checkbox"/> Livy 0.7.1	<input type="checkbox"/> MXNet 1.9.1	<input type="checkbox"/> Oozie 5.2.1			
<input type="checkbox"/> Phoenix 5.1.3	<input checked="" type="checkbox"/> Pig 0.17.0	<input type="checkbox"/> Presto 0.283			
<input type="checkbox"/> Spark 3.5.0	<input checked="" type="checkbox"/> Sqoop 1.4.7	<input type="checkbox"/> TensorFlow 2.11.0			
<input checked="" type="checkbox"/> Tez 0.10.2	<input type="checkbox"/> Trino 426	<input type="checkbox"/> Zeppelin 0.10.1			
<input type="checkbox"/> ZooKeeper 3.5.10					

INTRODUCCIÓN

- Utilizaremos el *dataset* <https://www.kaggle.com/datasets/alimortezaie/online-retail>.

CONTENIDO

APARTADO B

- Viene en formato Excel. Desde el propio Excel puedes convertirlo a formato 'csv'
- Crea una carpeta con tu nombre en el directorio *user* del HDFS de EMR
- Crea dentro de él una carpeta llamada *ventas* y sube a ella el 'csv' que obtuviste anteriormente.

CONTENIDO

APARTADO C



USANDO Pig

- Cargar los datos del *dataset* en PIG

Consultas:

- ¿Cuántos registros tiene la tabla?



- Mostrar registros con cantidades mayores o iguales a cero.
- A partir de la consulta anterior, mostrar registros precio mayor a cero
- A partir de la consulta anterior, mostrar solamente los registros con algún valor en el campo CustomerID.
- ¿Cuántos registros tiene la última consulta?
- Almacena la consulta final del punto 4 en un fichero llamado ventas.csv dentro de la carpeta de apartado B.

CONTENIDO

APARTADO D

Crear la tabla externa en Hive partiendo del fichero del punto anterior.

Conéctate al nodo maestro (SSH) o usa Hue.

- Crear base de datos
- Crear tabla externa sobre los datos RAW (CSV)
- Hive no maneja muy bien el formato de fecha original, conviértelo a d/M/yyyy H:mm
- Crea la misma estructura de tabla pero particionada por año y mes.
- Inserta los registros del punto 1.2 en la tabla particionada.

CONTENIDO

APARTADO E

Consultas con **HIVE**:

Análisis de clientes

- 10 clientes con mayor gasto total
- Clientes con más compras (cantidad de facturas)

Análisis de productos

- 10 productos más vendidos
- 10 Productos más rentables (suma de precio unitario por cantidad)

Análisis geográfico

- Países con mayor volumen de ventas

Análisis temporal

- Ventas totales por mes (suma de precio unitario por cantidad)
- Hora del día con más actividad

CONTENIDO

APARTADO F

SQOOP

- En tu servidor MySql en la máquina EC2 crea una base de datos y una tabla para almacenar los datos del fichero ventas.csv.
- Exporta con SQOOP los datos de ventas.csv a la tabla que creaste en el punto anterior.