



## Big Data

La finalidad de esta práctica es crear un Trabajos ETL (*ETL Jobs*) y disparadores en AWS Glue.

### INTRODUCCIÓN

- Vete haciendo capturas de pantalla de los pasos que des para resolver los ejercicios y añadiéndoles comentarios explicativos.

### CONTENIDO


#### APARTADO A

- Crea un *bucket S3* con una carpeta dentro, por ejemplo, **clima/espana**
- Mediante un comando AWS CLI, copia los archivos csv con las mediciones de todas las estaciones metereológicas de España en él. Recuerda que la ruta era: `s3://noaa-ghcn-pds/csv/by_station/`). Y que los ID's (nombre de fichero, por tanto) de las estaciones de España comenzaba por "SP".
- Crea una base de datos en del *Data Catalog* que se llame **espana**.
- Crea un *Crawler* que nos permita agregar a esa base de los ficheros de las estaciones meteorológicas de España (Pon como prefijo a la tabla **espcsv\_**).
- Guarda el *Crawler* pero **no lo ejecutes**.

### CONTENIDO

#### APARTADO B

- Crea una carpeta dentro del *bucket* anterior (**clima**) con el nombre **parquet**. por ejemplo, **clima/parquet**
- Crea un trabajo mediante Visual ETL que nos permita cambiar el esquema de los CSV's que acabamos de importar poniendo los nombres de los campos en español y guardando los datos en formato **parquet** en la carpeta del punto anterior.



- Guarda el trabajo, **pero no lo ejecutes**.

### CONTENIDO

#### APARTADO C

- Crea un *Crawler AWS GLUE* que nos explore el *bucket* del ejercicio anterior (*parquet*) generando la tabla correspondiente en la base de datos **clima**. Ponle de prefijo a la tabla **espparq\_**.
- Guarda el rastreador, **pero no lo ejecutes**.

### CONTENIDO

#### APARTADO D



## Big Data

- 1.- Crea un disparador (*trigger*) -puedes llamarlo **espa\_ab** - que después de finalizado el *crawler* del apartado A lance el *trabajo* del apartado B.
- 2.- Crea un disparador (*trigger*) -puedes llamarlo **espa\_bc** - que después de finalizado el trabajo del apartado B lance el *trabajo* del apartado C.
- 3.- Finalmente hemos de crear un *trigger* bajo demanda que nos arranque el *crawler* inicial (en nuestro caso el del apartado A)

**Set trigger properties**

**Trigger details**

Name  
  
Name can be up to 255 characters long. Some character set including control characters are prohibited.

Description - optional  
  
Descriptions can be up to 2048 characters long.

**Trigger type**

On demand  
Fire the trigger immediately when started.

Schedule  
Fire the trigger on a timer.

Job or crawler event  
Fire the trigger when job or crawler events match your watched list.

- 4.- Arranca este manualmente este último disparador.

### CONTENIDO

#### APARTADO E

- Deberían de ir ejecutándose todos los trabajos y *crawlers*. Cuando finalicen todas las tareas tendrían que haberse creado los archivos CSV y Parquet así como la tablas con los nombres de sus campos en español. Verifica que todo ha ido correctamente.
- 1.- Muestra los archivos creados.
  - 2.- Muestra las tablas y campos creados.

### CONTENIDO

#### APARTADO F

- Vete a Athena y ejecuta por duplicado (una vez sobre la tabla **espcsv\_** y otra sobre la tabla **espparq\_**) las mismas consultas que en la práctica anterior mostrando sus resultados y tiempos de ejecución. Obtén los tiempos obtenidos entonces y ahora sobre las dos tablas.
- 1.- ¿Cuántas mediciones tenemos de España?
  - 2.- Sabiendo los códigos de las 4 estaciones de Asturias ¿Cuántas mediciones tenemos de Asturias?
  - 3.- ¿Cuántas mediciones tenemos de Oviedo?
  - 4.- ¿Cuál es la medición más antigua de España, Asturias y Oviedo?
  - 5.- Haz una tabla comparativa con los tiempos de ejecución de las consultas sobre las tres diferentes tablas (las de la práctica anterior y las dos de esta práctica) ¿Cuáles han sido las más veloces?