



## Big Data

**La finalidad de esta práctica es utilizar las herramientas de descubrimiento, transformación y validación de datos que nos ofrece AWS Glue Databrew.**

### INTRODUCCIÓN

- Utilizaremos el CSV incluido en el archivo “*Hr1m.zip*” que es una colección de datos con un millón de registros relativos a recursos humanos generada aleatoriamente.

### CONTENIDO

#### APARTADO A

1.- Carga el CSV anterior en una carpeta llamada **raw** dentro de un *bucket* nombrado con algo similar a **rrhh**

2.- Desde *Databrew* crea una conexión de datos a dicha carpeta.

- ¿Cuánto ocupa el archivo?
- Haz una captura que nos muestre el tipo y contenido de las 5 primeras filas de algunas de las columnas. Se ven en la pestaña:



3.- Crea una carpeta dentro del *bucket* anterior llamada **perfil**.

4.- Genera el perfil de datos de dicho conjunto de datos. Deja la configuración por defecto. ¿Cuántas filas utiliza por defecto para el análisis?

5.- Analiza los datos obtenidos.

- ¿Cuántas columnas y de qué tipo tiene el conjunto de datos?
- ¿Hay alguna correlación positiva o negativa que te llame la atención?
- ¿Qué porcentaje de hombres y mujeres hay?
- Analizando el diagrama de cajas de los salarios ¿En qué horquilla se mueven? ¿Cuál es la media, mediana y moda? ¿Están distribuidos simétricamente?
- Busca la misma información para el campo *Age in years*.

6.- Haz una captura del contenido de la pestaña *Linaje de datos*. ¿Qué se muestra en ella?

### INTRODUCCIÓN

- En el siguiente apartado crearemos con el conjunto de datos anterior un proyecto en *Databrew* para realizar algunas trasnformaciones guardando el resultado de ellas en otra carpeta.

### CONTENIDO

#### APARTADO B

1.- Crea un proyecto con el conjunto de datos del apartado anterior. Deja los valores por defecto. ¿Cuántos registros utiliza por defecto para el muestreo?

2.- Generaremos una receta para realizar diferentes transformaciones a los datos:



- a) Fusión de varias columnas en una sola. Selecciona las columnas *Name Prefix*, *First Name*, *Middle Initial* y *Last Name* como columnas de origen. Añade un espacio como separador. Como nuevo nombre de columna pondremos, por ejemplo, *Nombre\_completo\_empleado*.
- b) Elimina las columnas *Short Month*, *DOW of Joining* y *Short DOW*
- c) Formatea la columna *Date of Joining* a la forma utilizada en España **dd/mm/yyyy**
- d) Renombra la columna *Phone No.* a *Telefono*
- e) Para enmascarar columnas confidenciales, cambiaremos el contenido de los campos número de la seguridad social, teléfono y contraseña por almohadillas. (Muestra cómo se hace pero no la apliques, ya que si no un paso posterior que tenemos que hacer nos dará un error)
- f) Realiza un cifrado determinista de los campos *E Mail* y *Date of Birth*.
- g) Agrupar por sexo. Agrupa los datos en función del sexo y calcula cuál es el salario medio de hombres y mujeres. Una vez hechos los cálculos elimina este paso.

ABC SSN X      ABC Telefono X  
ABC Password X

3.- Publica la receta.

4.- Crea en el *bucket* en el que estábamos trabajando una nueva carpeta llamada **transformado**.

5.- A partir de la receta anterior, crea un nuevo trabajo que nos deje los datos en formato CSV con comas en la carpeta del punto anterior.

6.- Descarga el CSV obtenido y échale una ojeada para verificar que se han realizado las transformaciones.

## INTRODUCCIÓN

- a) Una regla del manejo de datos dice "*La calidad de los datos de salida viene determinada por la calidad de los datos de entrada. Es decir, si proporcionamos datos malos como entrada, obtendremos datos malos como salida*".
- b) En el siguiente apartado realizaremos operaciones de validación de los datos obtenidos en el ejercicio anterior guardando el resultado del análisis en otra carpeta.

## CONTENIDO

### APARTADO C

1.- Crea en *Databrew* un conjunto de datos asociado al CSV de la carpeta **transformado**.

2.- Crea un conjunto de reglas de calidad de los datos asociado al *dataset* anterior.

3.- Añade las siguientes reglas:

- a) Valida el recuento de filas: Hemos utilizado un conjunto de datos de 1 millón de registros. Vamos a validar si el recuento coincide.
- b) El ID de empleado, la dirección de correo electrónico y el SSN deben ser únicos: Estos valores deben ser siempre únicos en el 100% de las filas.
- c) El ID de empleado y la dirección de correo electrónico no deben ser nulos: Normalmente, no queremos que estos valores sean nulos en el 100% de las filas.



- d) El ID del empleado y la edad del empleado en años no deben tener valores negativos y además la edad debe de estar entre 0 y 80. Para ello tienes que seleccionar al crear la regla la opción de la imagen para que te permita aplicar dos comprobaciones distintas.
- e) Verificar mediante una expresión regular (`^\d{3}-\d{2}-\d{4}$`) que el formato de los datos del SSN debe tener ser del tipo (xxx-xx-xxxx).

Ámbito de comprobación de calidad de los datos

Comprobación individual de cada columna ▾

4.- Crea el conjunto de reglas sin asociarlo a ningún trabajo.

## INTRODUCCIÓN

- a) En el siguiente apartado ejecutaremos nuestra comprobación de calidad de los datos asociando al *trabajo de perfil* el conjunto de reglas creado en el apartado anterior.

## CONTENIDO

### APARTADO D

1.- Dentro del *bucket* de la práctica, crea una nueva carpeta llamada **calidad** que utilizaremos posteriormente para almacenar la salida del análisis de calidad que vamos a realizar.

2.- Vete al apartado de reglas de calidad en *Databrew* y asocia las reglas creadas a un trabajo de perfil.

Nombre del conjunto de reglas de calidad de datos	Descripción	Conjunto asociado
rcd-rrhh-3	-	rrhh

- a) Aplica el trabajo a todo el *dataset*:

Muestra de datos  
Definir el ámbito del conjunto de datos en el que se va a ejecutar el trabajo  
 Conjunto de datos completo  
 Ejemplo personalizado  
20000 filas  
El valor debe ser mayor que cero

- b) Configura el *bucket* de salida del análisis en la carpeta del punto anterior.  
c) Verifica en rol adecuado en el apartado de *Permisos (Labrole)*. Crea el trabajo.

3.- Verifica el nombre del trabajo de perfil asociado a las reglas:



## Big Data

y posteriormente vete a trabajos de perfil y ejecútalo:

4.- Una vez ejecutado accede al enlace *Ver perfil de datos* y dentro de la pestaña *Reglas de calidad de datos* verifica el resultado de la comprobación de las reglas configuradas.

5.- De aparecer algún error (por ejemplo, en la imagen me dice que hay *SSN* y *Emp ID* repetidos ),

vete a la pestaña de *Estadísticas de columna* y comprueba que es cierto el error de las regla (por ejemplo, en la imagen puedo ver los *Emp ID* repetidos)

Value	Count	%
255047	3	<1%
372733	2	<1%
954733	2	<1%
389783	2	<1%
407135	2	<1%

### INTRODUCCIÓN

- a) Hemos verificado la calidad de los datos una vez transformados. En este ejercicio intentaremos corregir los errores detectados y mover los datos ya limpios (*curated*) al *bucket* final donde ya podrán ser tratados por los usuarios finales.

### CONTENIDO APARTADO E



- 1.- Crea en el *bucket* en el que estábamos trabajando una nueva carpeta llamada **curated**.
- 2.- De modo similar a como hicimos en el apartado B, crea un nuevo proyecto que a partir del conjunto de datos que tenemos en la carpeta **transformado** y mediante una nueva receta y un nuevo

trabajo intenta corregir los errores aparecidos en el ejercicio anterior (por ejemplo, eliminando filas con campos duplicados). El resultado del trabajo almacénalo en formato *parquet* comprimido en la carpeta **curated**.

- 3.- Crea un nuevo conjunto de datos en *Databrew* que apunte al archivo de **curated**.
- 4.- Verifica ahora las estadísticas de las columnas que has modificado para asegurarnos que todo ha ido bien (por ejemplo, que no haya datos repetidos en *Emp ID*). ¿Cuántas filas tiene ahora el archivo resultante?

### INTRODUCCIÓN

- a) En principio, en la carpeta **curated** deberíamos tener los datos ya totalmente limpios, Es hora de verificar si dicho archivo puede pasar

### CONTENIDO

#### APARTADO F

- 1.- Duplica el conjunto de reglas de calidad del **Apartado C**, pero ahora hazlo apuntar al *dataset* de la carpeta **curated**. Modifica alguna regla si fuese necesario, por ejemplo, la que nos contaba el número de filas. (Puede ser que los nombre de los campos hayan cambiado respecto a los originales, si es así modifícalos en el conjunto de reglas)
- 2.- Asocia dicho conjunto de reglas al *trabajo de perfil*.
- 3.- Ejecuta dicho trabajo contra todo el *dataset*.
- 4.- Verifica en el perfil de datos, apartado *Reglas de calidad* que se han pasado correctamente todas las comprobaciones.